

FEATURE ENGINEERING:

La Fábrica de Juguetes del Data Analyst

DIANA MARTÍNEZ



Made with GAMMA



¿Qué es el Feature Engineering?

El **feature engineering** es el proceso de transformar los datos "crudos" (sin procesar) en información que una máquina pueda entender y usar para aprender. La palabra *feature* significa **característica** o **variable**: cada pista que le damos al modelo.



Datos crudos

Información tal cual llega: números, fechas, textos sin ordenar.



Feature Engineering

El proceso de transformar esos datos en características útiles.



Modelo ML

La máquina aprende mejor con características bien preparadas.



Regla de oro: Un buen feature engineering puede ser más importante que el algoritmo que elijas. ¡Los datos bien preparados son el verdadero superpoder!

La Analogía: La Fábrica de Juguetes 🏭

Para entenderlo mejor, imagina una **fábrica de juguetes**. El objetivo es predecir qué juguetes serán **superventas** y cuáles tendrán ventas normales. Veamos cómo funciona cada parte del proceso:



El ingeniero de juguetes no trabaja con la materia prima tal cual llega. La **transforma, combina y selecciona** para que la máquina pueda aprender de forma inteligente. ¡Eso es feature engineering!

Los Ingredientes: ¿Qué Datos Tenemos?

En nuestra fábrica, cada juguete llega con información básica. Estos son los **datos crudos** que tenemos antes de empezar a trabajar:

1

Edad recomendada

¿Para qué edad es el juguete? (ej: 3-5 años, 6-8 años)

2

Precio

¿Cuánto cuesta? (ej: 12€, 35€, 80€)

3

Material

¿De qué está hecho? (plástico, madera, tela...)

4

Temporada

¿En qué época se vende más? (Navidad, verano, todo el año)

5

Color principal

¿Qué color predomina? (rojo, azul, rosa...)

6

Ventas históricas

¿Cuántas unidades se vendieron en el pasado?

Estos datos solos no son suficientes. El ingeniero debe **crear nuevas características** combinándolos de forma inteligente.



El Ingeniero en Acción: Creando Features

El ingeniero de juguetes toma los datos crudos y los **transforma**. Aquí tienes ejemplos de features que podría crear:



Precio por edad

Dividir el precio entre la edad recomendada. ¿Es caro para esa edad?



Es de temporada alta

¿El juguete se vende en Navidad? 1 = sí, 0 = no.



Color popular

¿El color está de moda este año?
Combinar color + temporada.



Categoría de precio

Clasificar en "barato", "medio" o "caro" según rangos definidos.

Cada nueva feature es una **pista más inteligente** para que el modelo aprenda mejor.
¡Cuanto más creativo sea el ingeniero, mejor predecirá la máquina!

¿Y esto cómo se hace en Python?

Ahora veamos cómo se traduce todo esto a código. En Python, usamos librerías como **pandas** para crear nuevas features a partir de las columnas de nuestro dataset:

Código de ejemplo

```
import pandas as pd
# Datos crudos
df = pd.DataFrame({
    'precio': [12, 35, 80, 20],
    'edad_min': [3, 6, 8, 4],
    'temporada': ['navidad', 'verano',
                  'navidad', 'todo']
})
# Feature engineering
df['precio_por_edad'] = (
    df['precio'] / df['edad_min']
)
df['es_navidad'] = (
    df['temporada'] == 'navidad'
).astype(int)
df['categoria_precio'] = pd.cut(
    df['precio'],
    bins=[0, 20, 50, 100],
    labels=['barato', 'medio', 'caro']
)
```

¿Qué hace cada línea?

- **precio_por_edad:** Divide el precio entre la edad mínima recomendada. Un valor alto puede indicar que el juguete es caro para esa franja de edad.
- **es_navidad:** Crea una variable binaria (1 o 0). Muy útil para que el modelo detecte patrones estacionales.
- **categoria_precio:** Agrupa los precios en categorías. A veces es más útil que el número exacto.



Estas nuevas columnas son las **features** que alimentarán al modelo de Machine Learning.

Machine Learning: La Máquina que Aprende 🤖

Una vez que el ingeniero ha creado las features, llega el turno del **modelo de Machine Learning**. Este modelo es como un aprendiz que observa muchos ejemplos y descubre patrones por sí solo.



El modelo **no sabe nada al principio**. Necesita ver muchos ejemplos de juguetes pasados (con sus features y el resultado de ventas) para aprender qué combinación de características lleva a una superventa.

80%

Datos de entrenamiento

El modelo aprende con el 80% de los juguetes históricos.

20%

Datos de prueba

El 20% restante sirve para evaluar si predice bien.

2

Clases a predecir

Superventas (1) o Ventas normales (0).

¿Por Qué es Tan Importante el Feature Engineering?

Podrías pensar: "¿No puede el modelo aprender solo con los datos crudos?" A veces sí, pero las features bien diseñadas marcan una **enorme diferencia**. Aquí te explicamos por qué:

Mejora la precisión

Un modelo con buenas features puede alcanzar un 90% de acierto, mientras que con datos crudos quizás solo llegue al 60%. La diferencia está en la calidad de las pistas que le damos.

Reduce la complejidad

Menos features pero más relevantes = modelo más rápido y fácil de explicar. No necesitamos darle toda la información, solo la que importa.

Revela patrones ocultos

Al combinar variables (como precio + temporada), el modelo puede descubrir relaciones que no eran evidentes a simple vista en los datos originales.

Resumen: Lo Que Has Aprendido Hoy 🌟

Has recorrido todo el camino, desde los datos crudos hasta la predicción con Machine Learning. Aquí tienes los conceptos clave para no olvidar:

01

Feature Engineering = Transformar datos en pistas útiles

No uses los datos tal cual llegan. Combínalos, calcúlalos y crea nuevas variables que aporten información valiosa al modelo.

03

Python y pandas son tus herramientas

Con operaciones simples sobre DataFrames puedes crear features poderosas: divisiones, categorías, variables binarias y combinaciones.

02

La analogía de la fábrica de juguetes

Materia prima → Ingeniero (crea features) → Control de calidad (selecciona las mejores) → Máquina ML (predice superventas).

04

El modelo ML aprende de tus features

Cuanto mejores sean las features, mejor aprenderá el modelo. El feature engineering es, muchas veces, más importante que el algoritmo elegido.

Dinámica Final: ¡Conviértete en Ingeniero de Juguetes!

Llega el momento de poner en práctica todo lo aprendido. En esta dinámica, cada uno será un **ingeniero de juguetes** con una misión clara: crear las mejores features para predecir superventas.

Tu misión

Trabajarás en un **Jupyter Notebook** con un dataset de juguetes reales. Deberás:

1. Explorar los datos crudos disponibles
2. Crear al menos **5 nuevas features** creativas
3. Entrenar un modelo de clasificación
4. Predecir: ¿superventas o ventas normales?
5. Justificar por qué elegiste esas features

Herramientas que usarás

- **Jupyter Notebook:** tu taller de ingeniero
- **pandas:** para manipular y crear features
- **scikit-learn:** para entrenar el modelo ML
- **matplotlib / seaborn:** para visualizar los datos

Criterio de éxito

Consigue la **mayor precisión** en la predicción y explica tus features.

La idea MÁS importante

El feature engineering no es solo programar. Es: entender el problema y transformar datos en información útil.

Eso es lo que diferencia: alguien que usa modelos de alguien que entiende los datos.

Regla de oro: "Mejores datos > modelos más complejos"

Muchas veces: un modelo simple con buen feature engineering gana a un modelo súper avanzando con datos mal preparados.

✓  **¡Ahora te toca a ti!** Abre tu Jupyter Notebook, conviértete en el mejor ingeniero de juguetes y demuestra que sabes crear features que hacen predecir al modelo como un experto.